







Politechnika  
Wrocławska

# Sieci złożone



HR EXCELLENCE IN RESEARCH

# Dane rzeczywiste




# A co jeżeli nie mamy:







# Sztuczne i darmowe




## Regular lattice




## Bethe lattice




## Fractal



## Random network



WS smallworld



BA scale free

# NETWORK REPOSITORY

# A SCIENTIFIC NETWORK DATA REPOSITORY WITH INTERACTIVE VISUALIZATION AND MINING TOOLS

The first interactive network repository with visual analytic tools  
The largest network repository with thousands of network data sets  
Interactive network visualization and mining  
Download thousands of real-world networks: from biological to social networks






# Model sieci losowej

- Erdős, P. Rényi, A (1959) "On Random Graphs I" in Publ. Math. Debrecen 6, p. 290–297
- Gilbert, E. N. (1959). Random graphs. *The Annals of Mathematical Statistics*, 30(4), 1141-1144.

# Model sieci losowej

- Erdős-Rényi model (1959) - Erdős, P. Rényi, A (1959)  
"On Random Graphs I" in Publ. Math. Debrecen 6, p.  
290–297



Paul Erdős (1913-1996)



Alfréd Rényi (1921-1970)

# Model sieci losowej - Erdős Number

## Erdos Number = 5

Piotr Bródka

coauthored with

Przemysław  
Kazienko

Przemysław  
Kazienko

coauthored with

Edwin Lughofer

Edwin Lughofer

coauthored with

Bernhard Alois  
Moser

Bernhard Alois  
Moser

coauthored with

István Joó

István Joó

coauthored with

Paul Erdős<sup>1</sup>

# Model sieci losowej

- **Model  $G(N,L)$  - Erdős-Rényi 1959**

- Erdős-Rényi model (1959) - Erdős, P. Rényi, A (1959) "On Random Graphs I" in Publ. Math. Debrecen 6, p. 290–297
- $N$  – liczba wierzchołków
- $L$  – liczba krawędzi losowo łącząca wierzchołki


- **Model  $G(N,p)$  – Gilbert 1959**

- Gilbert, E. N. (1959). Random graphs. *The Annals of Mathematical Statistics*, 30(4), 1141-1144.
- $N$  – liczba wierzchołków
- $p$  – prawdopodobieństwo istnienia krawędzi pomiędzy parą wierzchołków



# Model sieci losowej

- Graf losowy to graf posiadający  $N$  wierzchołków gdzie każda para wierzchołków jest połączona z prawdopodobieństwem  $p$




# Model sieci losowej

Aby zbudować losową sieć, postępuj zgodnie z następującymi krokami:


1. Zaczynij od  $N$  izolowanych węzłów.
2. Wybierz parę węzłów i wygeneruj losową liczbę z zakresu od 0 do 1. Jeśli liczba jest poniżej  $p$ , połącz wybraną parę węzłów krawędzią, w przeciwnym razie pozostaw je nie połączone.
3. Powtórz krok (2) dla każdej z  $N(N-1)/2$  par węzłów.

# Model sieci losowej


$N=12$ ,  $p=0.2$



$L=17$




$L=8$




$L=13$

# Model sieci losowej


$N=100$ ,  $p=0.02$



$L=101$



$L=106$



$L=152$



Politechnika  
Wrocławska

# Rozkład stopni wężła w sieciach losowych



HR EXCELLENCE IN RESEARCH



# Rozkład dwumianowy

- Rozkład dwumianowy to dyskretny rozkład prawdopodobieństwa opisujący liczbę sukcesów  $x$  w ciągu  $N$  niezależnych prób, z których każda ma stałe prawdopodobieństwo sukcesu równe  $p$ .
- Funkcja rozkładu prawdopodobieństwa

$$p_x = \binom{N}{x} p^x (1 - p)^{N-x}$$

- Wartość oczekiwana (średnia)

$$\langle x \rangle = \sum_{x=0}^N x p_x = Np$$

# Rozkład stopni wężła w sieciach losowych


W sieci losowej prawdopodobieństwo że wierzchołek  $i$  ma dokładnie  $k$  krawędzi składa się z trzech elementów:

1. Prawdopodobieństwa, że  $k$  jego krawędzi istnieje  $p^k$
2. Prawdopodobieństwa, że pozostałe  $(N-1-k)$  krawędzi nie istnieje  $(1-p)^{N-1-k}$
3. Liczby kombinacji bez powtórzeń wyboru  $k$  krawędzi ze zbioru  $N - 1$  potencjalnych krawędzi  $\binom{N-1}{k}$


W konsekwencji rozkład stopni wężła w sieci losowej jest rozkładem dwumianowym.

$$p_k = \binom{N-1}{k} p^k (1-p)^{N-1-k} \qquad \langle k \rangle = \sum_{k=0}^{N-1} k p_k = (N-1)p$$

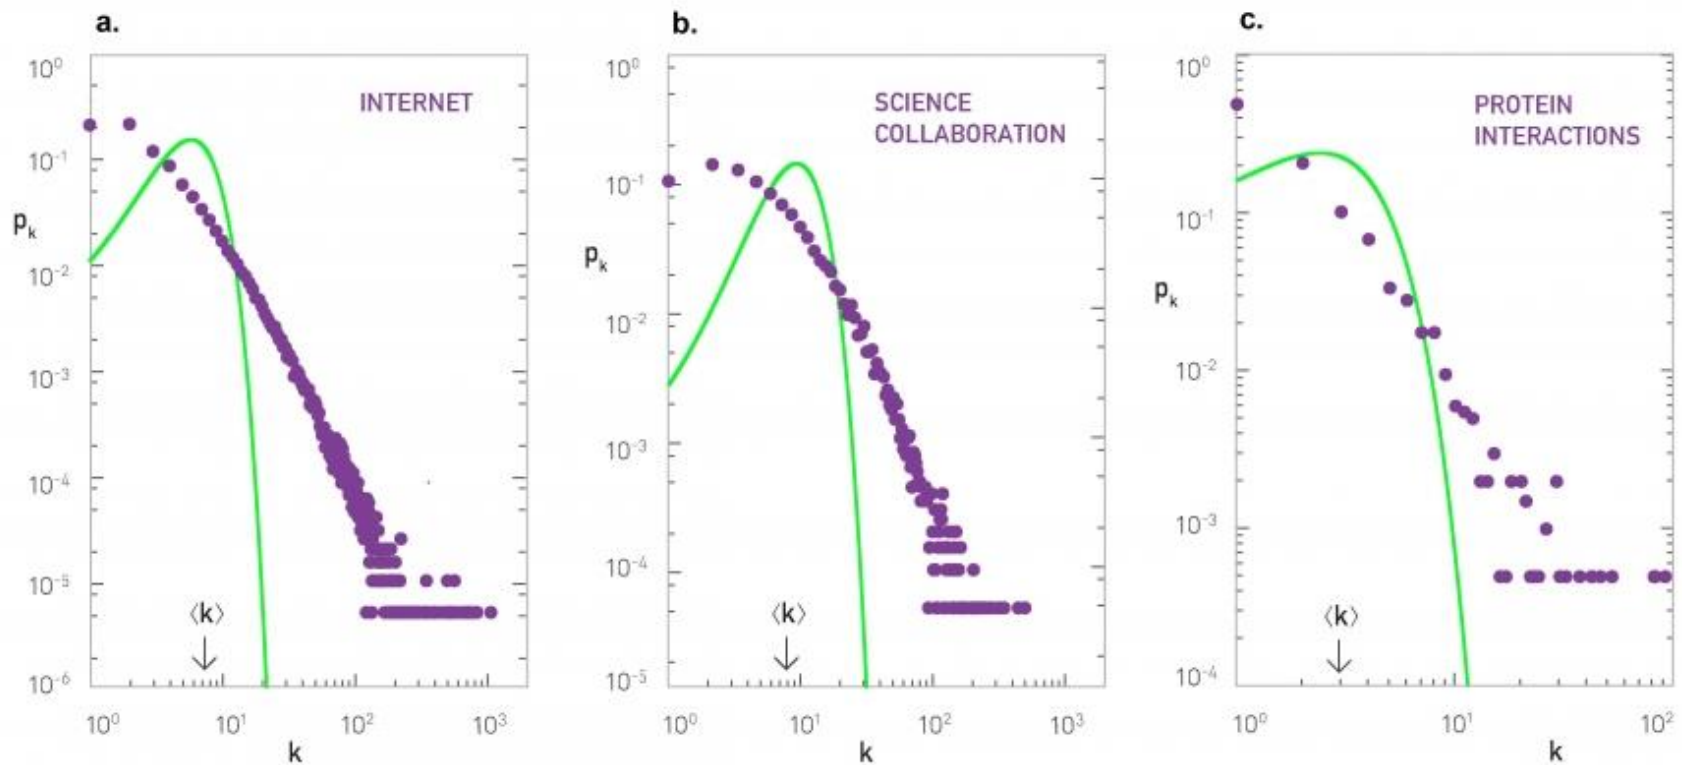
# Rozkład stopni wężła w sieciach losowych



# Rozkład stopni wężła w sieci losowej a rozmiar sieci



# Rzeczywiste sieci nie są losowe







Politechnika  
Wrocławska


# Połączeniowość w sieciach losowych




HR EXCELLENCE IN RESEARCH


# Ewolucja sieci losowej

Od izolowanych węzłów do połączonej sieci






- „Brak” wielkiego komponentu
- N-L izolowanych grup/klastrów
- Największy klaster ma rozmiar  $\sim \ln N$




- Unikalny największy komponent:  $N_G \sim N^{2/3}$  (Barabasi Advanced Topics 3.C)
  - $N=1\ 000$  -  $\ln_N \sim 6.9$ ;  $N^{2/3} \sim 95$
  - $N=7\ 000\ 000\ 000$  -  $\ln_N \sim 22$ ;  $N^{2/3} \sim 3,659,250$
- Pozostałe komponenty to zazwyczaj drzewa, natomiast największy komponent zazwyczaj ma cykle



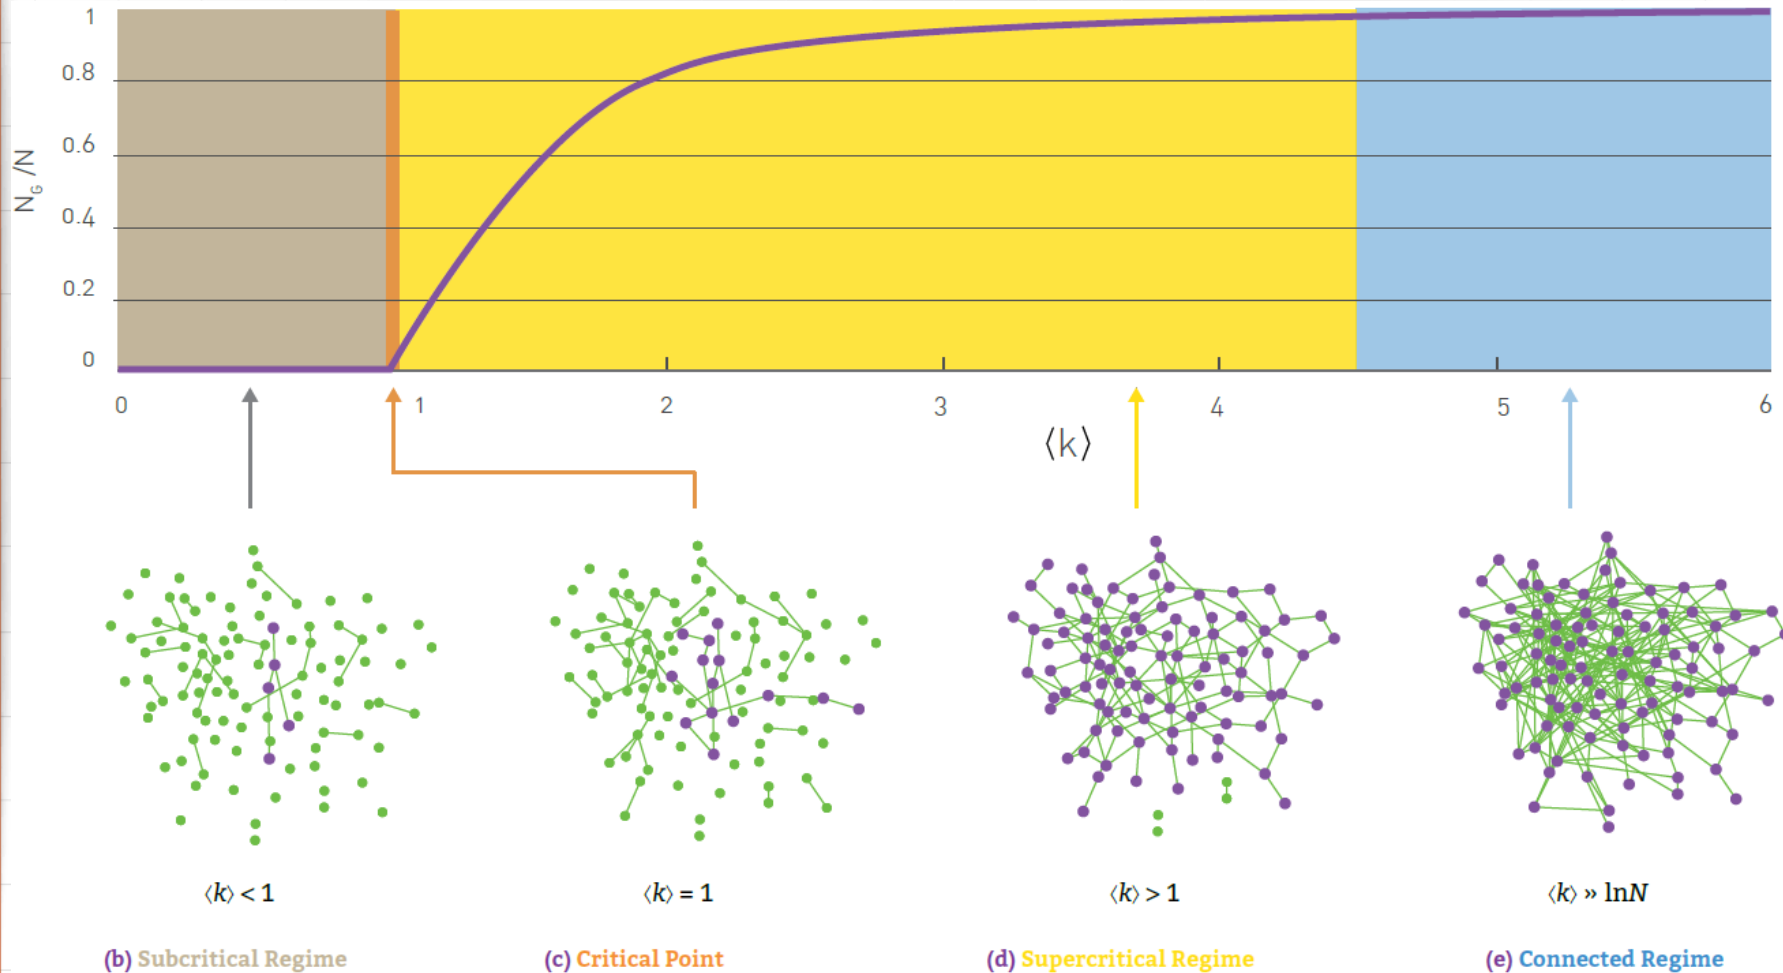
- Unikalny największy komponent:  $N_G \sim (p - p_c)N = pN - 1$
- Pozostałe komponenty to zazwyczaj drzewa, natomiast największy komponent zazwyczaj ma cykle

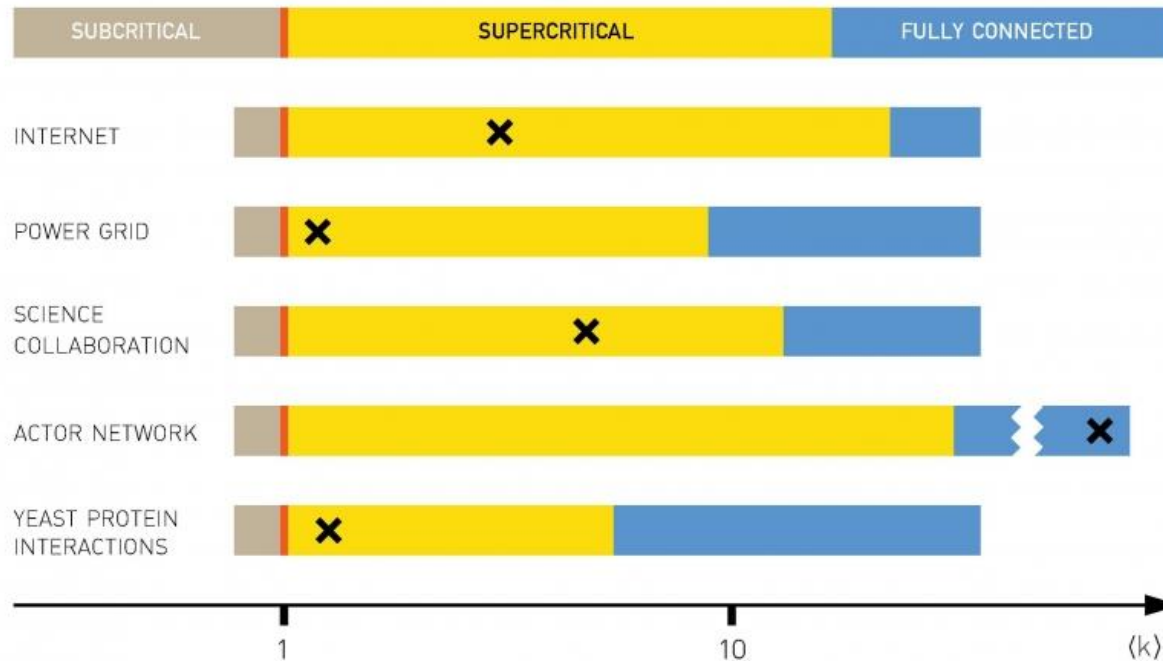




- Jeden największy komponent:  $N_G = N_G = N$
- Brak izolowanych wierzchołków lub komponentów

# Czy sieci rzeczywiste są zgodne z modelem ewolucji sieci losowej?





Sieć	N	L	$\langle k \rangle$	$\ln_N$
Internet	192,244	609,066	6.34	12.17
Sieć energetyczna	4,941	6,594	2.67	8.51
Współpraca naukowa	23,133	93,437	8.08	10.05
Sieć aktorów	702,388	29,397,908	83.71	13.46
Interakcje pomiędzy proteinami	2,018	2,930	2.90	7.61



Politechnika  
Wrocławska

# Dystans w sieciach losowych

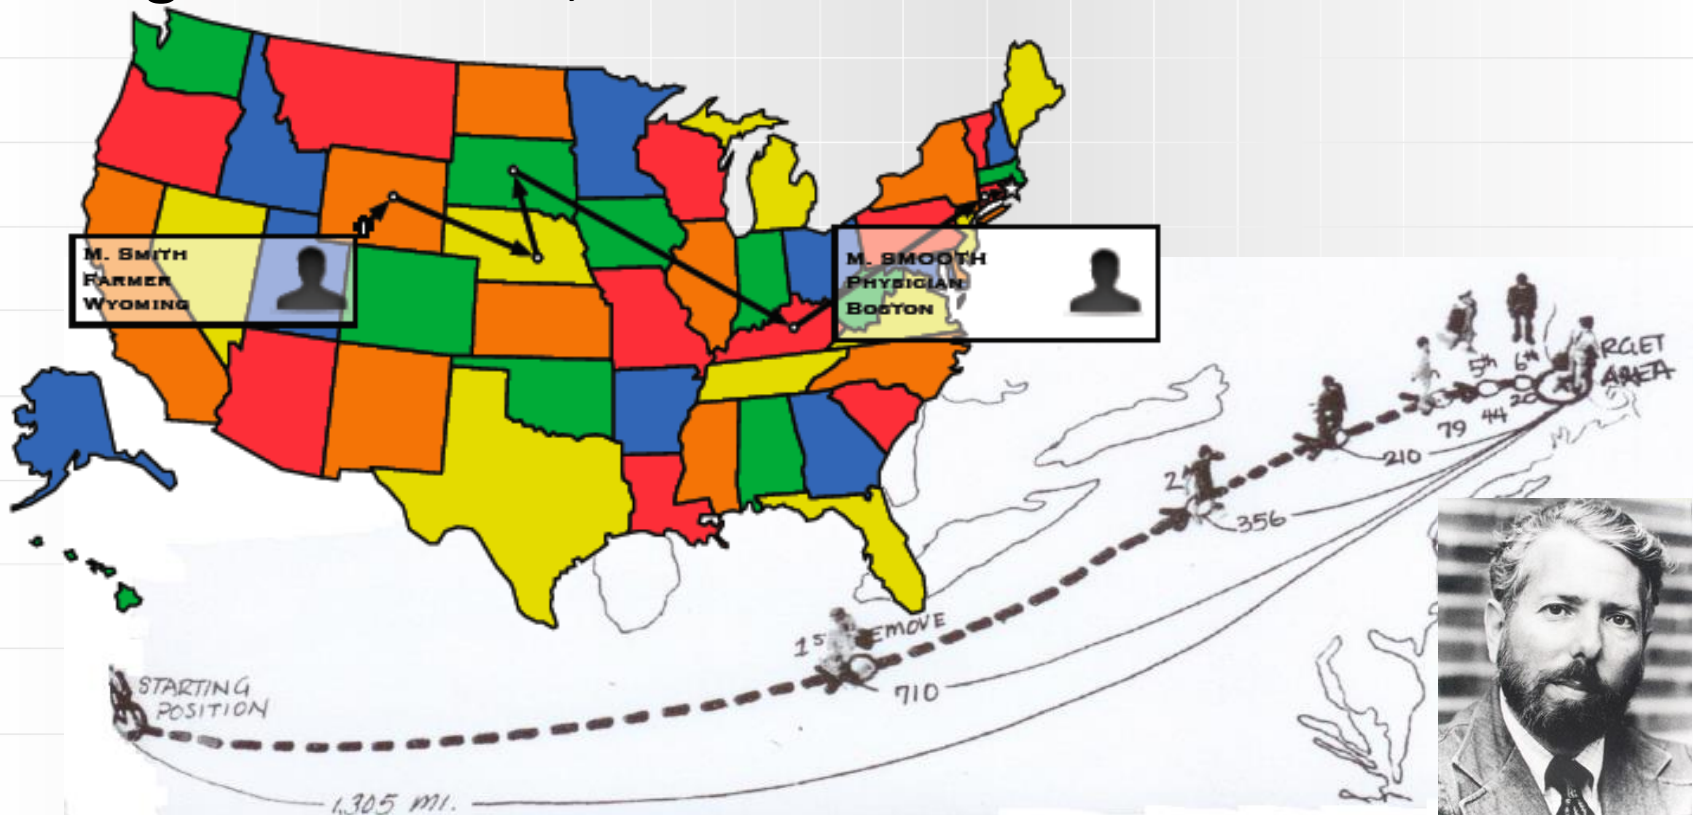


HR EXCELLENCE IN RESEARCH

J. Travers and S. Milgram. An experimental study of the small world problem.  
Sociometry, 32(4), 1969

# Fenomen małego świata

- 1967, makler giełdowy mieszkający pod Bostonem
- 300 listów z Kansas i Nebraski, 64 dotarło, Średnia długość ścieżki: 5,2





Dodds, P. S., Muhamad, R., & Watts, D. J. (2003). **An experimental study of search in global social networks.** *Science*, 301(5634), 827-829.

# Fenomen małego świata - powtórka

- 2003 Columbia University,
- 18 celów z 13 krajów,
- email,
- 98 847 (61 168) uczestników ze 166 krajów,
- 24 163 ścieżki
- 384 dotarło do celu
- $\langle L \rangle = 4.05$
- $5 \leq L_* \leq 7$

# Fenomen małego świata - powtórka

- Jure Leskovec (Carnegie Mellon University, teraz Stanford), Eric Horvitz (Microsoft Research)
- Microsoft Instant Messenger (taki dzisiejszy WhatsApp)
- Czerwiec 2006, 30 miliardów konwersacji, 240 miliony ludzi
- Sieć  $N=180\,000\,000$ ,  $E = 1\,300\,000\,000$
- $\langle L \rangle = 6,6$  „*We investigate [...] report that people are separated by “six degrees of separation” and find that the average path length among Messenger users is 6.6*”

# Fenomen małego świata – Facebook i Twitter

- Facebook


- Backstrom, L., Boldi, P., Rosa, M., Ugander, J., & Vigna, S. (2012, June). **Four degrees of separation**. *4th Annual ACM Web Science Conference* (pp. 33-42).
- 721 milionów kont, 69 miliardy „przyjaźni”
- $\langle L \rangle = 4,74$

- Twitter

- Bakhshandeh, R., Samadi, M., Azimifar, Z., & Schaeffer, J. (2011, July). Degrees of separation in social networks. In *Fourth Annual Symposium on Combinatorial Search*.
- 1 500 losowych par na Twitterze
- $\langle L \rangle = 3,43$


Albert, R., Jeong, H., & Barabási, A. L. (1999). Diameter of the world-wide web. *nature*, 401(6749), 130-131.

# WWW: 8 degrees of separation



# Dystans w sieciach losowych

- Grafy losowe mają zwykle topologię podobną do drzewa z prawie stałymi stopniami węzłów.
  - $\langle k \rangle$  wierzchołków w odległości jeden  $d=1$
  - $\langle k \rangle^2$  wierzchołków w odległości dwa  $d=2$
  - ...
  - $\langle k \rangle^n$  wierzchołków w odległości  $n$   $d=n$



$$d_{max} = \frac{\ln N}{\ln \langle k \rangle}$$

# Dystans w sieciach losowych

$$d_{max} = \frac{\ln N}{\ln \langle k \rangle}$$

- Dla większości sieci to równanie dokładniej wyznacza oczekiwaną średnią długość najkrótszych ścieżek w sieci.

$$\langle d \rangle = \frac{\ln N}{\ln \langle k \rangle}$$

- Zjawisko małego świata to właściwość polegająca na tym, że średnia długość ścieżki lub średnica sieci zależy logarytmicznie od rozmiaru systemu. Stąd „mały” oznacza, że  $\langle d \rangle$  jest proporcjonalne do  $\ln N$ , a nie  $N$ .
- Wyrażenie  $\frac{1}{\ln \langle k \rangle}$  oznacza, że im gęstsza sieć, tym mniejsza będzie odległość między węzłami.

# Dystans w sieciach losowych

Sieć	N	L	$\langle k \rangle$	$\langle d \rangle$	$d_{\max}$	$\ln N / \ln \langle k \rangle$
Internet	192,244	609,066	6.34	6.98	26	6.58
WWW	325,729	1,497,134	4.60	11.27	93	8.31
Sieć energetyczna	4,941	6,594	2.67	18.99	46	8.66
Rozmowy telefoniczne	36,595	91,826	2.51	11.72	39	11.42
Emaile	57,194	103,731	1.81	5.88	18	18.4
Współpraca naukowa	23,133	93,437	8.08	5.35	15	4.81
Sieć aktorów	702,388	29,397,908	83.71	3.91	14	3.04
Sieć cytowań	449,673	4,707,958	10.43	11.21	42	5.55
Metabolizm Ecoli	1,039	5,802	5.58	2.98	8	4.04
Interakcje pomiędzy proteinami	2,018	2,930	2.90	5.61	14	7.14



Politechnika  
Wrocławska

# Współczynnik grupowania w sieciach losowych



HR EXCELLENCE IN RESEARCH







# Współczynnik grupowania

$$C_i = \frac{2e_i}{k_i(k_i - 1)} \qquad \langle L_i \rangle = p \frac{k_i(k_i - 1)}{2}$$

$$C_i = \frac{2\langle L_i \rangle}{k_i(k_i - 1)} = p = \frac{\langle k \rangle}{N}$$

# Współ





Politechnika  
Wrocławska

# Sieci rzeczywiste a grafy losowe



HR EXCELLENCE IN RESEARCH



# Rozkład stopni węzła


- Powinno być

$$p_k = \binom{N-1}{k} p^k (1-p)^{N-1-k}$$

$$P(k) = e^{-\langle k \rangle} \frac{\langle k \rangle^k}{k!}$$


- Jest

$$P(k) \gg k^{-g}$$





# Połączeniowość



Sieć	N	L	$\langle k \rangle$	$\ln_N$
Internet	192,244	609,066	6.34	12.17
Sieć energetyczna	4,941	6,594	2.67	8.51
Współpraca naukowa	23,133	93,437	8.08	10.05
Sieć aktorów	702,388	29,397,908	83.71	13.46
Interakcje pomiędzy proteinami	2,018	2,930	2.90	7.61




# Dystans

- Powinno być

$$\langle d \rangle = \frac{\ln N}{\ln \langle k \rangle}$$

- Jest

$$\langle d \rangle \approx \frac{\ln N}{\ln \langle k \rangle}$$






# Współczynnik grupowania





- Powinno być

$$C_i = \frac{2\langle L_i \rangle}{k_i(k_i - 1)} = p = \frac{\langle k \rangle}{N}.$$

- Jest
  - C potrafi być kilka rzędów większe
  - C zależy od k
  - dla sieci o podobnym  $\langle k \rangle$ , C nie zależy od rozmiaru sieci.



# Czy prawdziwe sieci są grafami losowymi?

- Gdy 20 lat temu zaczęły pojawiać się dane na temat dużych sieci okazało się że nie.
- Rozkład stopni wężła 
- Połączeniowość 
- Dystans 
- Współczynnik grupowania 



# Jeśli jest to błędny model to dlaczego się o nim uczyliśmy?

- Jest to model referencyjny (tzw. null model)
- Pomaga obliczyć wiele wielkości, które można następnie porównać z rzeczywistymi danymi, rozumiejąc, w jakim stopniu dana właściwość jest wynikiem jakiegoś losowego procesu.
  - np. pomagają zidentyfikować cechy sieci rzeczywistych, które są współdzielone przez dużą liczbę rzeczywistych sieci, ale odbiegają od przewidywań losowego modelu sieci.
  - Aby je zidentyfikować, musimy zrozumieć, jak wyglądałaby konkretna właściwość, gdyby była napędzana wyłącznie przez procesy losowe.
- **Chociaż model jest błędny dalej jest przydatny**



Politechnika  
Wrocławska

# Model Watts i Strogatza




HR EXCELLENCE IN RESEARCH

Watts, D. J., & Strogatz, S. H. (1998). Collective dynamics of 'small-world' networks. *Nature*, 393(6684), 440-442.


# Model Watts i Strogatza

- Watts-Strogatz Model (Small-World model)
- Analiza sieci rzeczywistych
- Dwie kluczowe obserwacje
  - **Właściwość małego świata** (niewielka średnica sieci, krótkie dystanse pomiędzy wierzchołkami)
  - **Bardzo duże zgrupowanie** - wysoki średni współczynnik grupowania w sieciach (o kilka rzędów wyższy niż w sieciach losowych)

# Model Watts i Strogatz



# Model Watts i Strogatza



# Czy prawdziwe sieci są sieciami WS?

- Rozkład stopni węzła



- Połączeniowość



- Dystans



- Współczynnik grupowania





Politechnika  
Wrocławska

# Model Barabási-Albert

Barabási, A. L., & Albert, R. (1999). Emergence of scaling in random networks. *Science*, 286(5439), 509-512.

Albert, R., & Barabási, A. L. (2002). Statistical mechanics of complex networks. *Reviews of modern physics*, 74(1), 47.



HR EXCELLENCE IN RESEARCH




# Huby

- Huby reprezentują najbardziej uderzającą różnicę między siecią losową a siecią bez skalowania. Ich pojawienie się w wielu rzeczywistych systemach rodzi fundamentalne pytania:
  - Dlaczego model sieci losowej Erdősa i Rényi nie przewiduje hubów ani wielu innych cech obserwowanych w wielu rzeczywistych sieciach?
  - Dlaczego tak różne systemy, takie jak WWW, sieć energetyczna lub interakcje pomiędzy białkami, tworzą podobną bezskalową (scale-free) topologię sieci?



# Wzrost (Growth)

- Sieć losowa – liczba węzłów (N) jest statyczna.
- Sieci rzeczywiste ewoluują i rosną wraz z pojawianiem się nowych wierzchołków i krawędzi.



# Preferencyjne łączenie (Preferential attachment)

- Sieć losowa – krawędzie pomiędzy wierzchołkami są dodawane w losowy sposób
- W sieciach rzeczywistych wierzchołki często „preferują” tworzenie połączeń z istotnymi węzłami w sieci.

Barabási, A. L., & Albert, R. (1999). Emergence of scaling in random networks. *Science*, 286(5439), 509-512.


# Wzrost i preferencyjne łączenie

1. Sieci stale się rozwijają dzięki dodawaniu nowych węzłów – w każdym kroku dodaj  $m$  nowych wierzchołków
2. Nowe węzły wolą łączyć się z silnie połączonymi węzłami.

$$\Pi(k_i) = \frac{k_i}{\sum_j k_j}$$

Przykład sieć WWW



1. Nowe strony
2. Linki do istniejących znanych stron






# Model Barabási-Albert

- $m_0$  - początkowa liczba wierzchołków tworzących graf pełny
- $m$  – liczba krawędzi dodawanych wraz każdym nowym wierzchołkiem
- $t$  – liczba dodawanych wierzchołków

# Brak wzrostu lub preferencyjnego dołączania




# Degree distribution




# Sieć losowa a sieć bezskalowa (BA)


a. POISSON



b.




c. POWER LAW



d.




# Huby – stopień węzła





Bollobás, B., & Riordan, O. (2004). The diameter of a scale-free random graph. *Combinatorica*, 24(1), 5-34.

# Średnica i dystans



Klemm, K., & Eguiluz, V. M. (2002). Growing scale-free networks with small-world behavior. *Physical Review E*, 65(5), 057102.


# Współczynnika grupowania

- W sieciach losowych

$$C_i = \frac{2\langle L_i \rangle}{k_i(k_i - 1)} = p = \frac{\langle k \rangle}{N}.$$

- W sieciach BA

$$C = \frac{m}{8} \frac{(\ln N)^2}{N}$$




# Model Barabási-Albert

- Liczba wierzchołków
  - $N = m_0 + t \approx t$  (dla dużych  $t$ )
- Liczba krawędzi
  - $L = m_0(m_0 - 1)/2 + mt \approx mt$  (dla dużych  $t$ )
- Średni stopień wężła
  - $\langle k \rangle = (m_0(m_0 - 1) + 2mt)/(m_0 + t) \approx 2m$  (dla dużych  $t$ )
- Rozkład stopni wężła
  - $p_k \approx k^{-\gamma}, 2 < \gamma < 3$
- Średnia długość ścieżki
  - $\langle d \rangle \approx \ln N / \ln(\ln N)$
- Średni współczynnik grupowania
  - $\langle C \rangle \approx (\ln N)^2 / N$

# Model Barabási-Albert

- $m_0 = 2$
- $m = 2$
- $t = 9$
- $N = m_0 + t = 11$
- $L = m_0(m_0 - 1)/2 + mt = 19$
- $\langle k \rangle = (m_0(m_0 - 1) + 2mt)/(m_0 + t) = 3,45$



# Model Barabási-Albert

- $m_0 = 2$
- $m = 2$
- $t = 1000$
- $N = m_0 + t = 1002 \approx t$
- $L = m_0(m_0 - 1)/2 + mt = 2001 \approx mt$
- $\langle k \rangle = (m_0(m_0 - 1) + 2mt)/(m_0 + t) = 3,99 \approx 2m$

# Model BA nie jest w stanie opisać wielu cech rzeczywistych systemów

- Model przewiduje  $\gamma=3$ , podczas gdy wykładnik stopnia rzeczywistych sieci waha się od 2 do 5
- Wiele sieci, takich jak WWW czy sieci cytowań, jest skierowanych, podczas gdy model generuje sieci nieskierowane.
- Wiele procesów obserwowanych w sieciach, od łączenia się z już istniejącymi węzłami do zanikania krawędzi i znikania węzłów, jest nieobecnych w modelu.
- Model nie pozwala nam na rozróżnienie węzłów na podstawie pewnych wewnętrznych cech, takich jak nowość artykułu naukowego lub użyteczność strony internetowej.

Broido, A. D., & Clauset, A. (2019). Scale-free networks are rare. *Nature communications*, 10(1), 1-10.

# *Scale-free networks are rare*

- Centralnym twierdzeniem we współczesnej nauce o sieciach jest to, że sieci w świecie rzeczywistym są zazwyczaj „bezskalowe” (scale free), co oznacza, że ułamek węzłów o stopniu  $k$  jest zgodny z prawem potęgowym, rozpadając się jak  $k^{-\gamma}$ , często z  $2 < \gamma < 3$ .
- 1 000 sieci społecznych, biologicznych, technologicznych i informacyjnych
- Tylko 4% z nich jest bezskalowa (scale free)

# Pytania

